

Порождающие состязательные сети

Сергей Николенко

НИУ ВШЭ – Санкт-Петербург

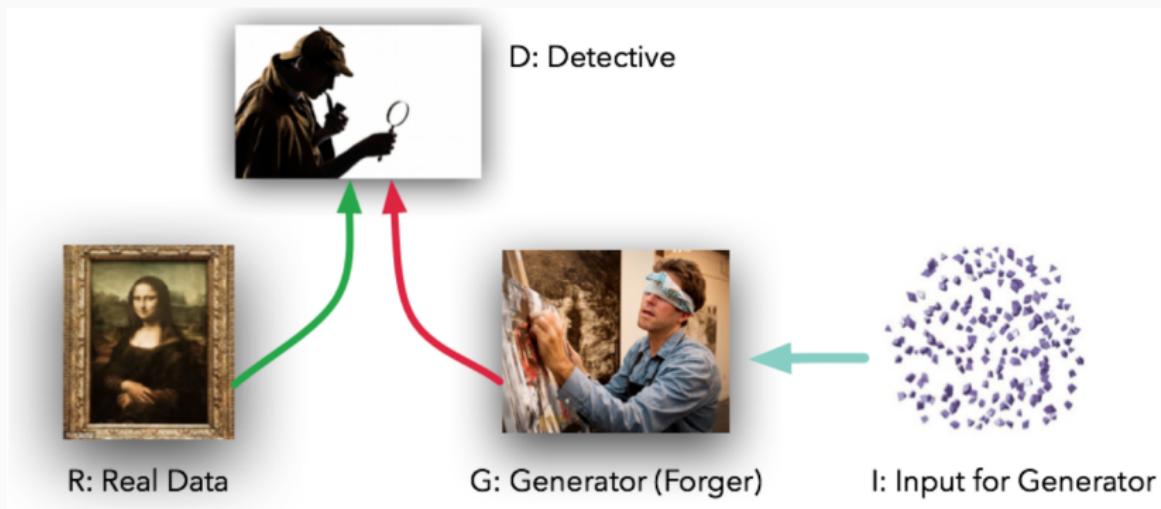
28 ноября 2020 г.

Random facts:

- 28 ноября 1814 г. лондонская The Times стала первой газетой, производившейся на паровом печатном прессе, созданном немецкими инженерами Кёнигом и Бауэром
- 28 ноября 1918 г. в Эстонию вошли российские войска, части РККА заняли Нарву, и началась Освободительная Война (1918–1920)
- 28 ноября 1905 г. Артур Гриффит основал политическую партию под названием Sinn Féin
- 28 ноября 1990 г. Маргарет Тэтчер ушла в отставку как глава консервативной партии и, как следствие, как премьер-министр; её преемником на обеих позициях стал Джон Мейджор

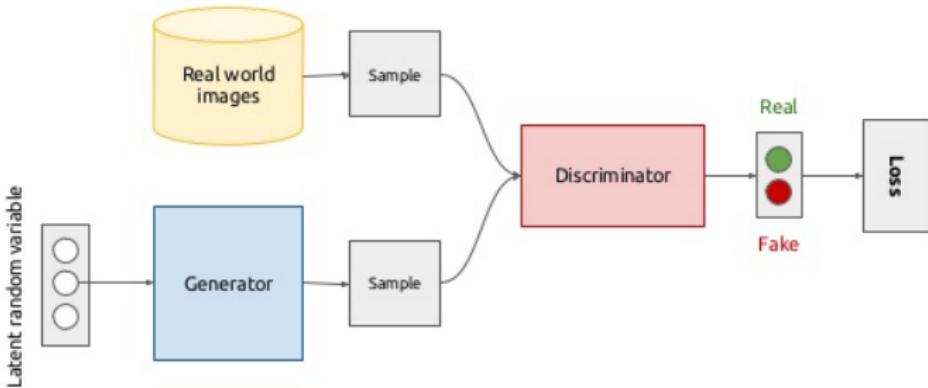
Порождающие соперничающие сети

- Порождающие соперничающие сети (Generative adversarial networks, GAN): генератор vs. дискриминатор, p_{data} vs. p_g .

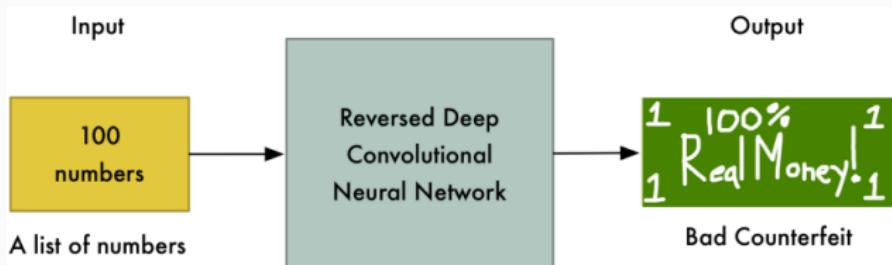


- Порождающие соперничающие сети (Generative adversarial networks, GAN): генератор vs. дискриминатор, p_{data} vs. p_g .

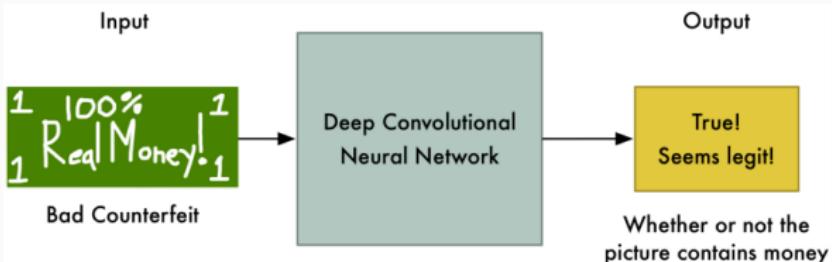
Generative adversarial networks (conceptual)



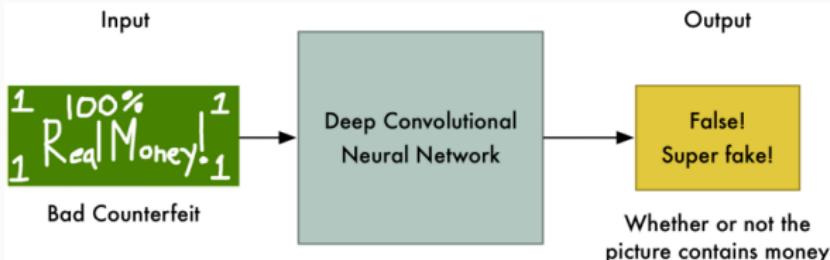
- В идеале должно быть примерно так (Geitgey, 2017):
 - сначала генератор плохой:



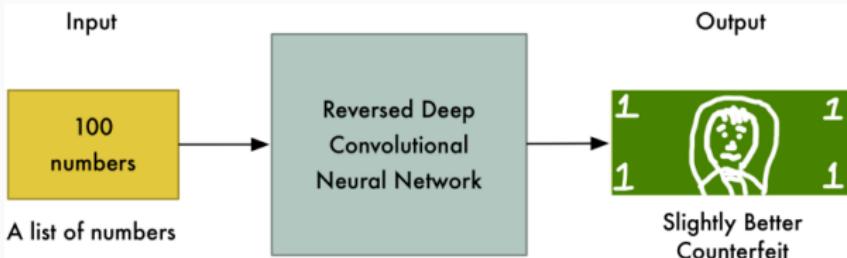
- но и дискриминатор ничего не умеет:



- В идеале должно быть примерно так (Geitgey, 2017):
 - поэтому сначала чуть обучим дискриминатор:



- ...и генератору придётся придумать что-то получше:



- И так они будут продолжать, пока всё не получится.

- Формально, генератор – это функция

$$G = G(\mathbf{z}; \boldsymbol{\theta}_g) : Z \rightarrow X,$$

а дискриминатор – это функция

$$D = D(\mathbf{x}; \boldsymbol{\theta}_d) : X \rightarrow [0, 1].$$

- Целевая функция для дискриминатора – это бинарная классификация:

$$E_{\mathbf{x} \sim p_{\text{data}}(\mathbf{x})} [\log D(\mathbf{x})] + E_{\mathbf{x} \sim p_g(\mathbf{x})} [\log(1 - D(\mathbf{x}))],$$

где $p_g(\mathbf{x}) = G_{\mathbf{z} \sim p_z}(\mathbf{z})$ – распределение, порождённое G ; то есть мы берём два мини-батча, с метками 0 из генератора и с метками 1 из данных.

- А генератор обучается обманывать дискриминатор, то есть минимизировать

$$\mathbb{E}_{x \sim p_g(x)} [\log(1 - D(x))] = \mathbb{E}_{z \sim p_z(z)} [\log(1 - D(G(z)))] .$$

- И теперь, если их объединить, получится типичная минимакс-игра:

$$\min_G \max_D V(D, G), \text{ где}$$

$$V(D, G) = \mathbb{E}_{x \sim p_{\text{data}}(x)} [\log D(x)] + \mathbb{E}_{z \sim p_z(z)} [\log(1 - D(G(z)))] .$$

- Можно доказать, что $\max_D V(D, G)$ минимизируется именно тогда, когда $p_g = p_{\text{data}}$.
- Важное свойство: для фиксированного генератора G оптимальное распределение дискриминатора D — это распределение

$$D_G^*(x) = \frac{p_{\text{data}}(x)}{p_{\text{data}}(x) + p_g(x)}.$$

- (Упражнение: попробуйте это доказать)

- Глобальный минимум критерия достигается тогда и только тогда, когда $p_g = p_{\text{data}}$; сам критерий для оптимального D эквивалентен

$$\text{KL} \left(p_{\text{data}} \middle\| \frac{p_{\text{data}} + p_g}{2} \right) + \text{KL} \left(p_g \middle\| \frac{p_{\text{data}} + p_g}{2} \right),$$

это т.н. дивергенция Йенсена–Шеннона (Jensen–Shannon divergence).

- Но это всё результаты для ошибки генератора $E_{z \sim p_z(z)} [\log(1 - D(G(z)))]$.
- А это не самая лучшая функция ошибки для генератора...

- Чем плохо минимизировать $E_{z \sim p_z(z)}[\log(1 - D(G(z)))]$?
 - перекрёстная энтропия хороша в классификаторе: если ответ неправильный, она не насыщается, а если правильный, насыщается и не меняется;
 - тут получается, что когда дискриминатор хорошо работает, его градиент обнуляется...
 - ...и градиент генератора тоже обнуляется!
- Поэтому на самом деле минимизируют

$$-E_{z \sim p_z(z)}[\log D(G(z))],$$

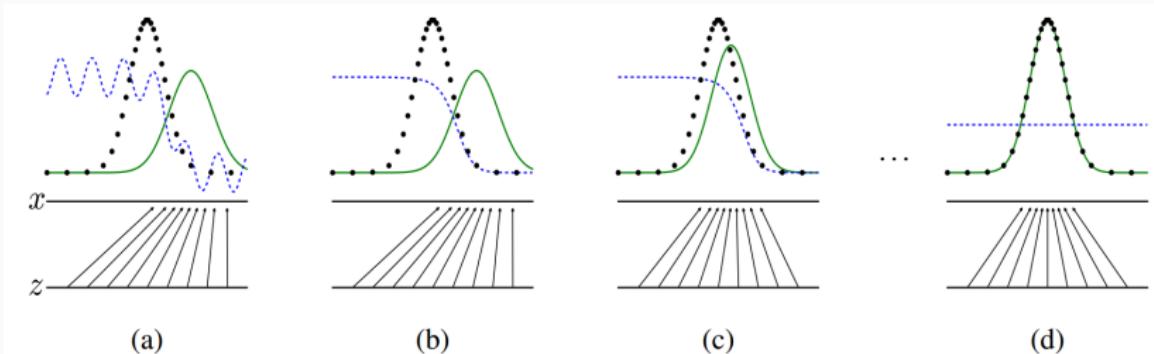
т.е. максимизируем вероятность того, что D ошибся, а не минимизируем вероятность его правильного ответа.

- Обучение похоже по сути на EM-алгоритм – попеременно:
 - фиксируем G , обновляем дискриминатор с функцией ошибки

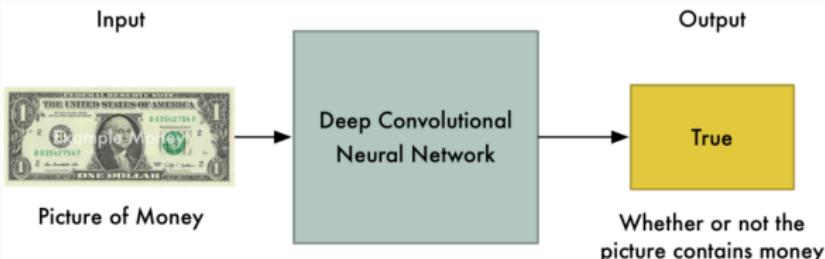
$$E_{x \sim p_{\text{data}}(x)} [\log D(x)] + E_{x \sim p_g(x)} [\log(1 - D(x))],$$

- фиксируем D , обновляем генератор с функцией ошибки

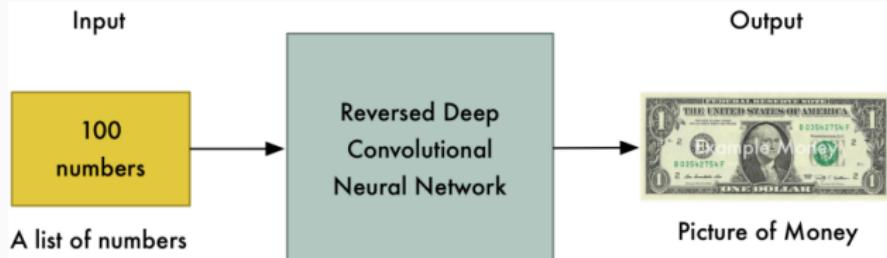
$$-E_{x \sim p_{\text{data}}(x)} [\log D(x)],$$



- В идеале должно быть примерно так (Geitgey, 2017):
 - дискриминатор пытается распознавать:



- а генератор хочет порождать:



GAN

- Сэмплирование из GAN (Goodfellow et al., 2014):



a)



b)



c)

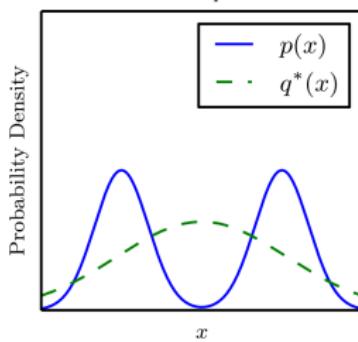


d)

Почему и как GAN работает?

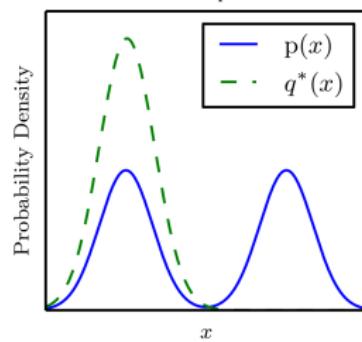
- Почему GAN хорошо работает?
 - возможно, потому что минимакс эквивалентен не $\text{KL}(p_{\text{data}} \parallel p_{\text{model}})$, а дивергенции Йенсена–Шеннона, что больше похоже на $\text{KL}(p_{\text{model}} \parallel p_{\text{data}})$:

$$q^* = \operatorname{argmin}_q D_{\text{KL}}(p \parallel q)$$



Maximum likelihood

$$q^* = \operatorname{argmin}_q D_{\text{KL}}(q \parallel p)$$



Reverse KL

Почему и как GAN работает?

- Почему GAN хорошо работает?
 - но нет, можно и другие функции ошибки брать (максимизировать правдоподобие, например), и всё равно хорошо;
 - ещё это напоминает обучение с подкреплением: генератор получает награду за действия; но так себе похоже: G знает градиенты D , а сам D сильно меняется со временем.

Почему и как GAN работает?

- Практические советы из ранней истории GAN:
 - всегда помогают метки – сэмплы становятся гораздо лучше, если давать метки классов, причём даже если давать их только дискриминатору (Salimans et al., 2016);
 - сглаживание меток (label smoothing): D оценивает отношение распределений, а нейронные сети любят быть слишком уверены; поэтому цель для p_{data} меняем с 1 на 0.9, чтобы D не был слишком уверен; а на p_{model} не надо сглаживать.

Почему и как GAN работает?

- Но хороши! И ещё лучше, если выполнять практические советы:
 - виртуальная нормализация по мини-батчам: вариации в мини-батче делают сэмплы скоррелированными; можно виртуально добавить reference batch и учитывать его в статистиках.

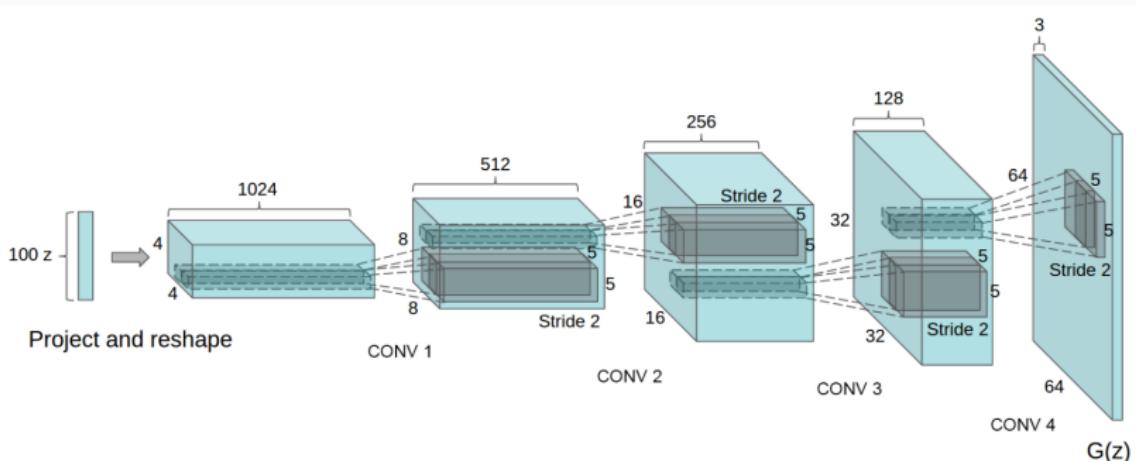


Почему и как GAN работает?

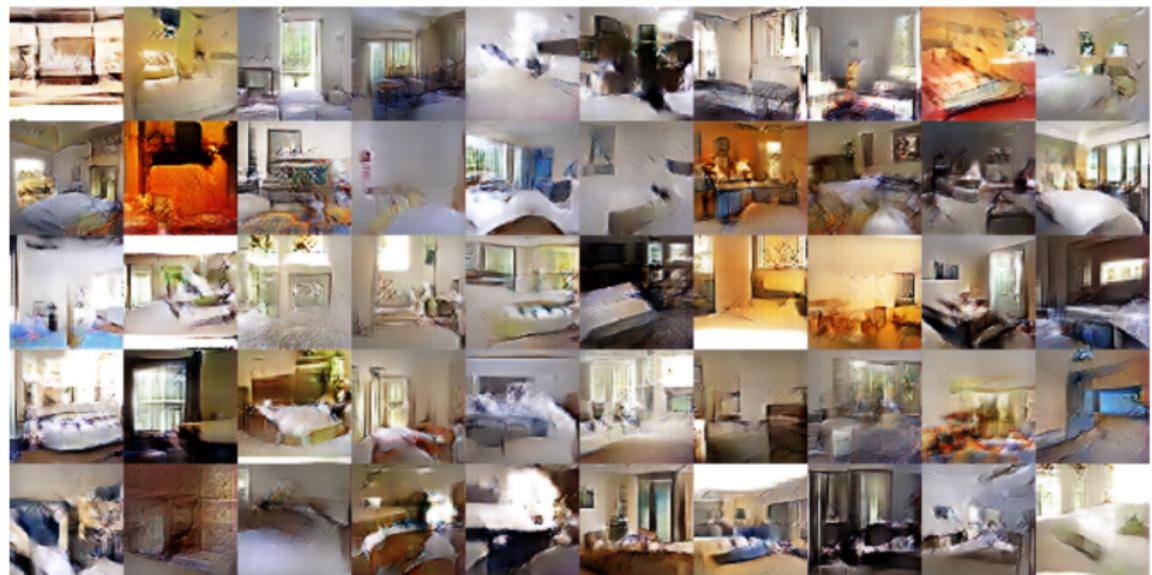
- Но хороши! И ещё лучше, если выполнять практические советы:
 - не надо балансировать G и D : мы обучаем отношение распределений, и оно хорошо оценивается, если D оптимален, т.е. пусть D будет «сильнее»;
 - на практике это значит, что D может быть более сложной сетью; просто дольше обучать D не особенно помогает;
 - пока не очень решённая проблема – diversity; GAN часто производит очень похожие сэмплы, mode collapse.
- Это советы из ранних статей, сейчас они всё ещё важны, но применимы не всегда.

DCGAN

- DCGAN – Deep Convolutional Generative Adversarial Networks (Radford et al., 2016).
- Несколько новых трюков (свёртки с пропусками вместо пулинга, везде batchnorm, убираем полно связные слои, Adam...)



- Спальни (LSUN) после одной эпохи:



- Спальни (LSUN) после пяти эпох:



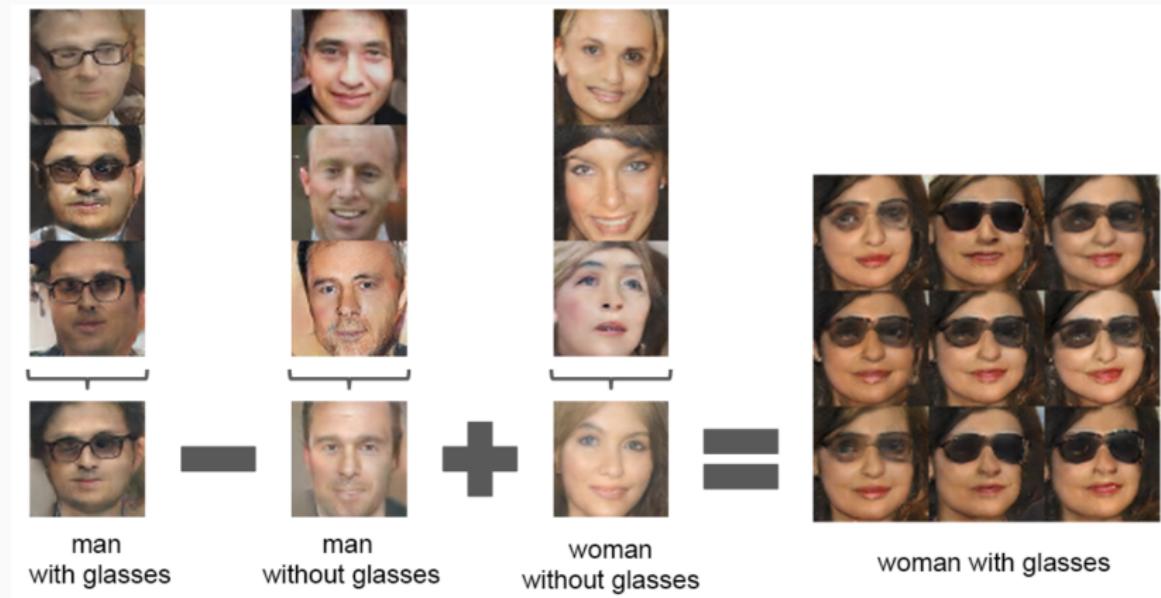
- Прогулка по пространству признаков:



- Убираем фильтры, распознающие окна:



- Векторная арифметика (как в *word2vec*):



DCGAN

- (Geitgey, 2017): pixel art из игр NES



adventureisland
d2a.jpg

adventurei
d2b.jpg

an AdventureIsland4_Game.gi

Adventure Island

Adventure
Island 4
(English
v1_0).gif

Adventure
Island 4
(English
v1_0)1.gif

Adventure
Island 4
(English
v1_0)2.gif

Adventure
Island 4
(English
v1_0)3.gif



Adventures of Bayou Billy, The (E)0.gif

Adventures of Bayou Billy, The (E)1.gif

of Adventures of
y, Bayou Billy,
if The (E)2.gif

Adventures
Captain
Comic, The
(U)0.gif

Adventures o
Captain
Comic, The
(U)1.gif

Adventures of
Captain
Comic, The
(U)2.gif

Adventures of
Dino Riki.gif

Adventures of Dino Riki - Ingame.gif



Adventures of
Ice Mario
(SMB1 Hack)
(UNL)0.gif

Adventures of
Ice Mario
(SMB1 Hack)
(UNL)1.gif

of Adventures
Ice Mario
(SMB1 Hack)
(UNL)2.gif

Adventures
Lolo 2 (J)0.g

Adventures of Lolo 2 (J)1.gi

Adventures of
Lolo 2 (J)2.git

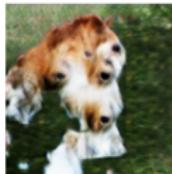
Adventures Of Lolo 3.gif

Adventures Of Lolo 3 - Ingame.gif

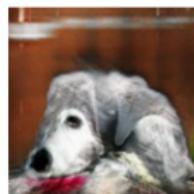
- Анимация:

<https://medium.com/@ageitgey/abusing-generative-adversarial-networks-to-make-fake-images-4a003c3d0e0f>

- Но не всегда, конечно, работает – проблемы с подсчётом:



- Но не всегда, конечно, работает – проблемы с перспективой (right?):



Прогресс

- Так работали самые первые GAN'ы.
- Но мы с тех пор прошли долгий путь:

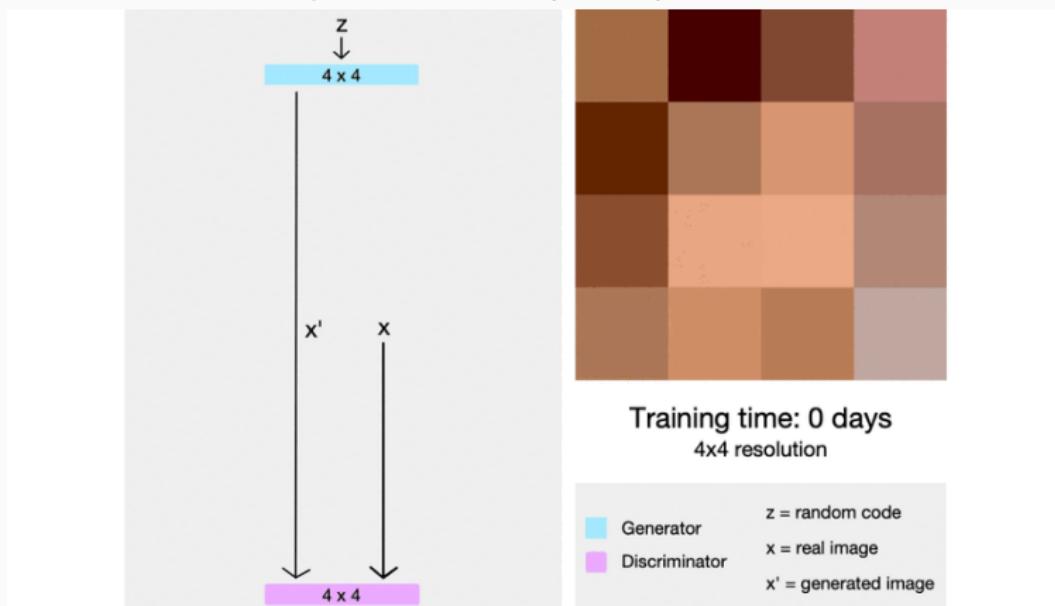


- Как же так получилось?

Enlarge your GAN

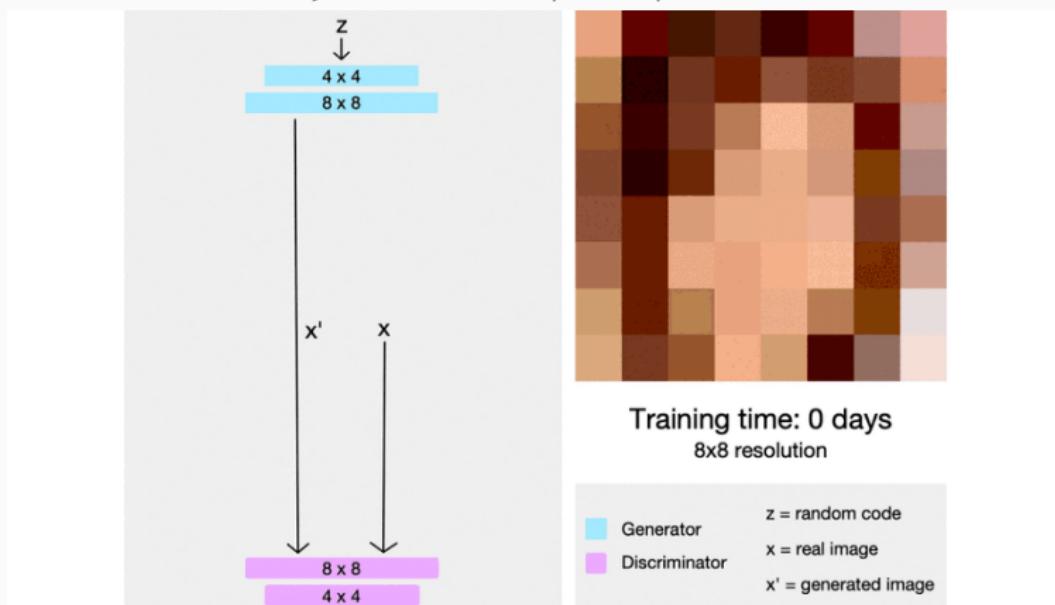
ProGAN

- Важный прорыв пришёл из NVIDIA (Karras et al., 2017)
- Progressive growing (ProGAN): на каждом этапе обучаем GAN создавать картинки вчетверо больше, начиная от 4×4
- И так постепенно увеличиваю размерность до 1024×1024



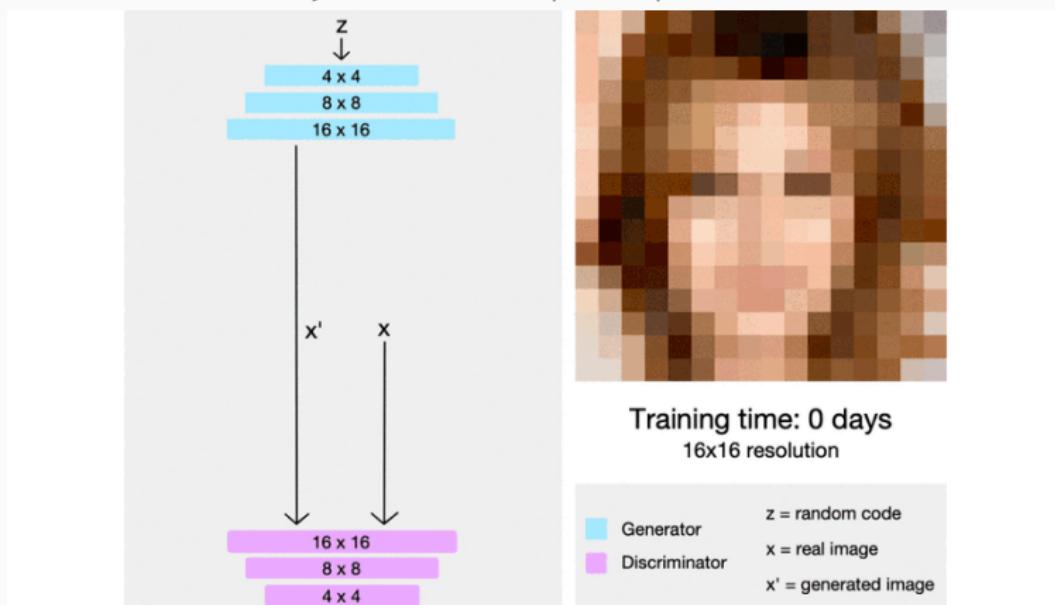
ProGAN

- Важный прорыв пришёл из NVIDIA (Karras et al., 2017)
- Progressive growing (ProGAN): на каждом этапе обучаем GAN создавать картинки вчетверо больше, начиная от 4×4
- И так постепенно увеличивают размерность до 1024×1024



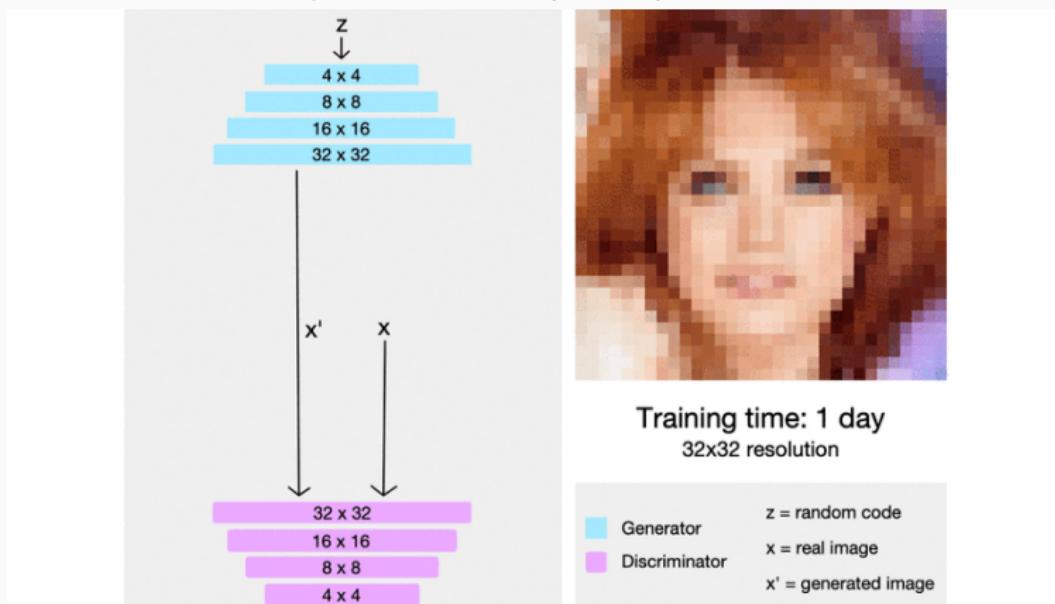
ProGAN

- Важный прорыв пришёл из NVIDIA (Karras et al., 2017)
- Progressive growing (ProGAN): на каждом этапе обучаем GAN создавать картинки вчетверо больше, начиная от 4×4
- И так постепенно увеличивают размерность до 1024×1024



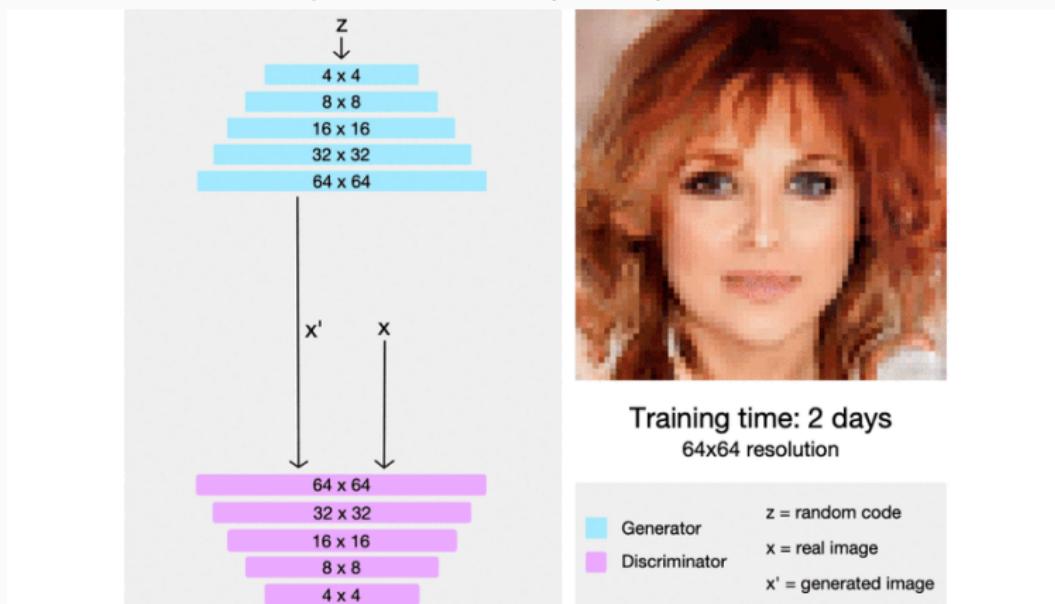
ProGAN

- Важный прорыв пришёл из NVIDIA (Karras et al., 2017)
- Progressive growing (ProGAN): на каждом этапе обучаем GAN создавать картинки вчетверо больше, начиная от 4×4
- И так постепенно увеличивают размерность до 1024×1024



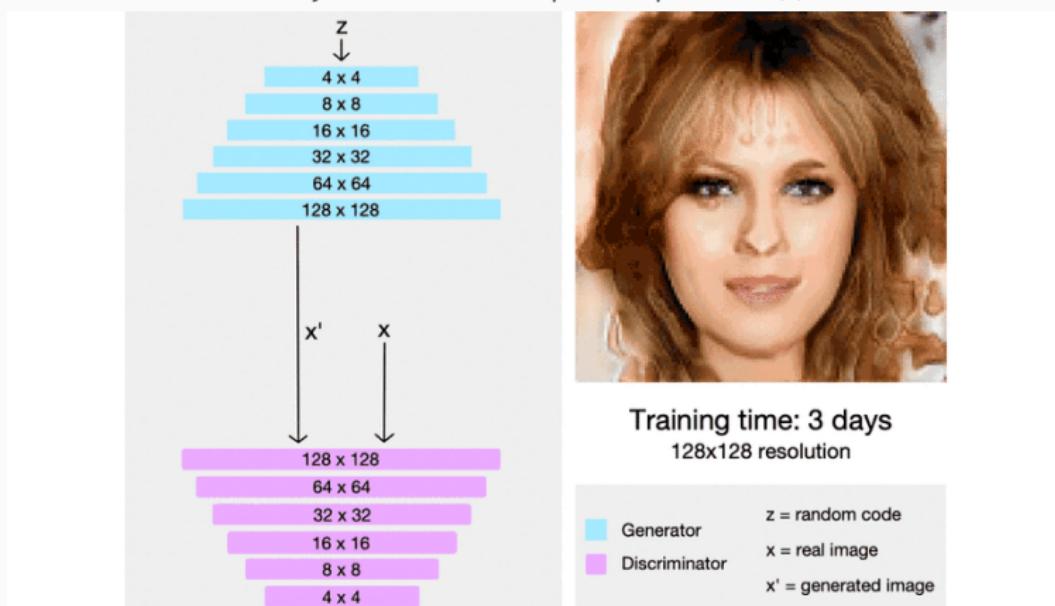
ProGAN

- Важный прорыв пришёл из NVIDIA (Karras et al., 2017)
- Progressive growing (ProGAN): на каждом этапе обучаем GAN создавать картинки вчетверо больше, начиная от 4×4
- И так постепенно увеличивают размерность до 1024×1024



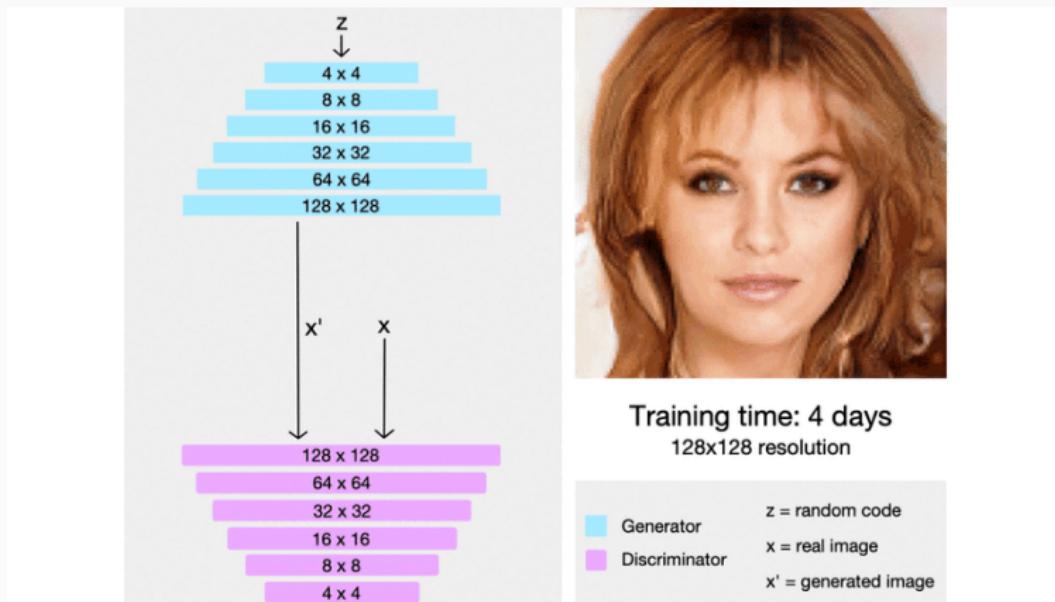
ProGAN

- Важный прорыв пришёл из NVIDIA (Karras et al., 2017)
- Progressive growing (ProGAN): на каждом этапе обучаем GAN создавать картинки вчетверо больше, начиная от 4×4
- И так постепенно увеличивают размерность до 1024×1024



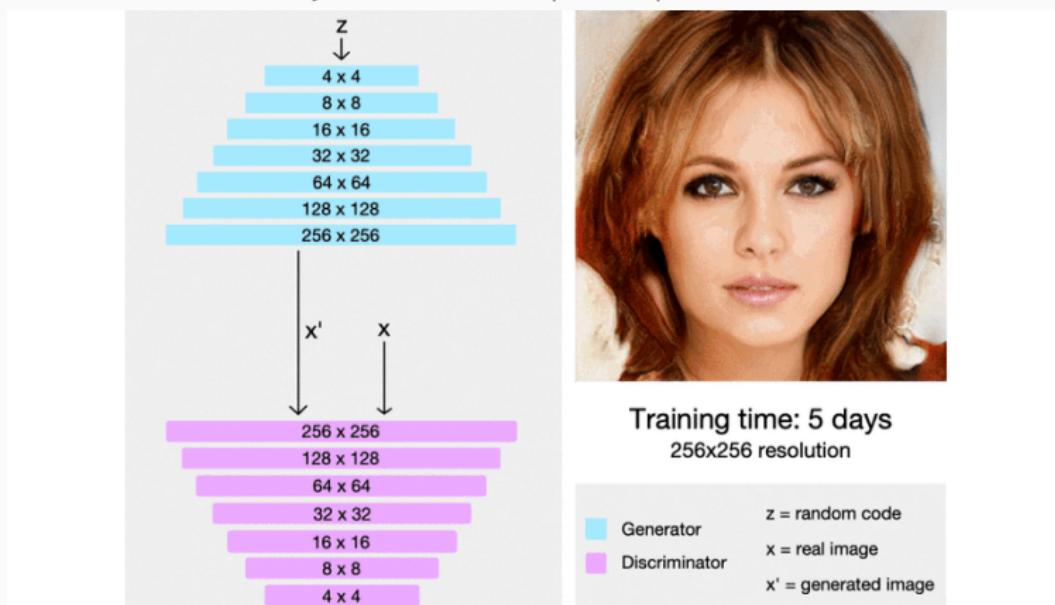
ProGAN

- Важный прорыв пришёл из NVIDIA (Karras et al., 2017)
- Progressive growing (ProGAN): на каждом этапе обучаем GAN создавать картинки вчетверо больше, начиная от 4×4
- И так постепенно увеличивают размерность до 1024×1024



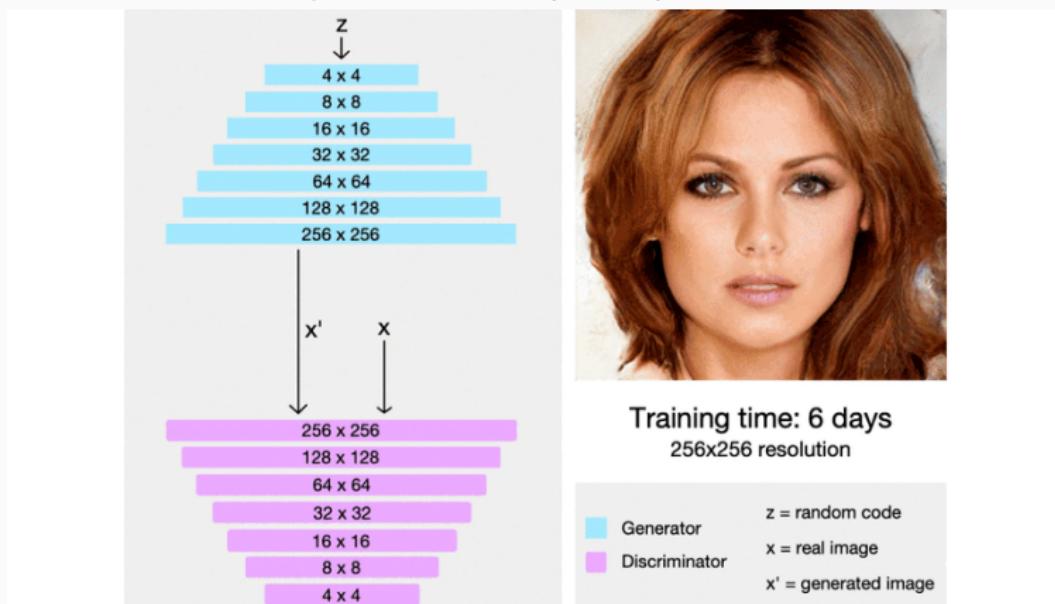
ProGAN

- Важный прорыв пришёл из NVIDIA (Karras et al., 2017)
- Progressive growing (ProGAN): на каждом этапе обучаем GAN создавать картинки вчетверо больше, начиная от 4×4
- И так постепенно увеличивают размерность до 1024×1024



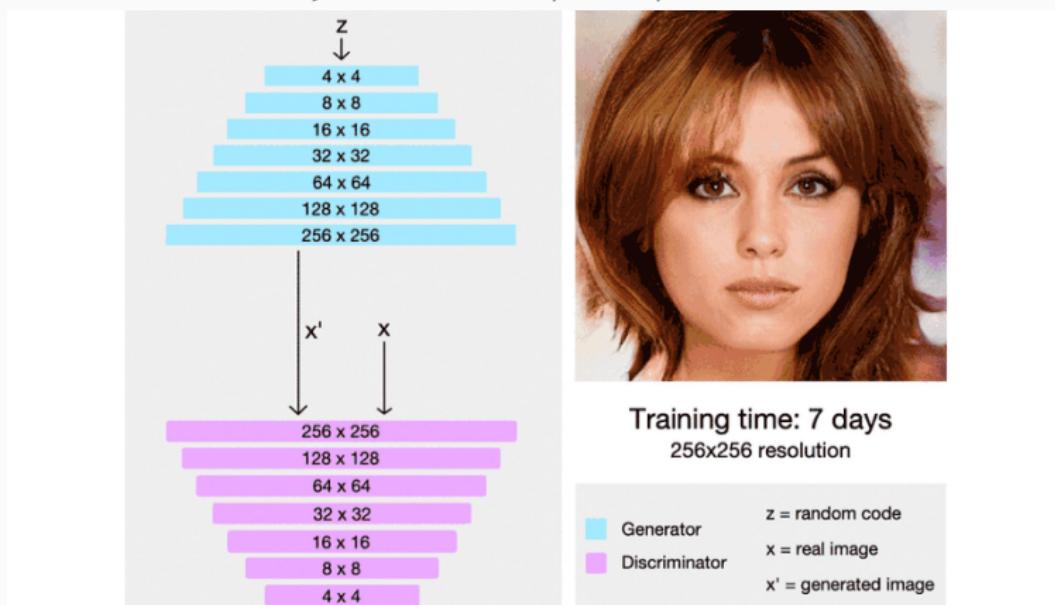
ProGAN

- Важный прорыв пришёл из NVIDIA (Karras et al., 2017)
- Progressive growing (ProGAN): на каждом этапе обучаем GAN создавать картинки вчетверо больше, начиная от 4×4
- И так постепенно увеличивают размерность до 1024×1024



ProGAN

- Важный прорыв пришёл из NVIDIA (Karras et al., 2017)
- Progressive growing (ProGAN): на каждом этапе обучаем GAN создавать картинки вчетверо больше, начиная от 4×4
- И так постепенно увеличивают размерность до 1024×1024



ProGAN

- Важный прорыв пришёл из NVIDIA (Karras et al., 2017)
- Progressive growing (ProGAN): на каждом этапе обучаем GAN создавать картинки вчетверо больше, начиная от 4×4
- И так постепенно увеличивают размерность до 1024×1024



ProGAN

- Важный прорыв пришёл из NVIDIA (Karras et al., 2017)
- Progressive growing (ProGAN): на каждом этапе обучаем GAN создавать картинки вчетверо больше, начиная от 4×4
- И так постепенно увеличивают размерность до 1024×1024



ProGAN

- Важный прорыв пришёл из NVIDIA (Karras et al., 2017)
- Progressive growing (ProGAN): на каждом этапе обучаем GAN создавать картинки вчетверо больше, начиная от 4×4
- И так постепенно увеличивают размерность до 1024×1024



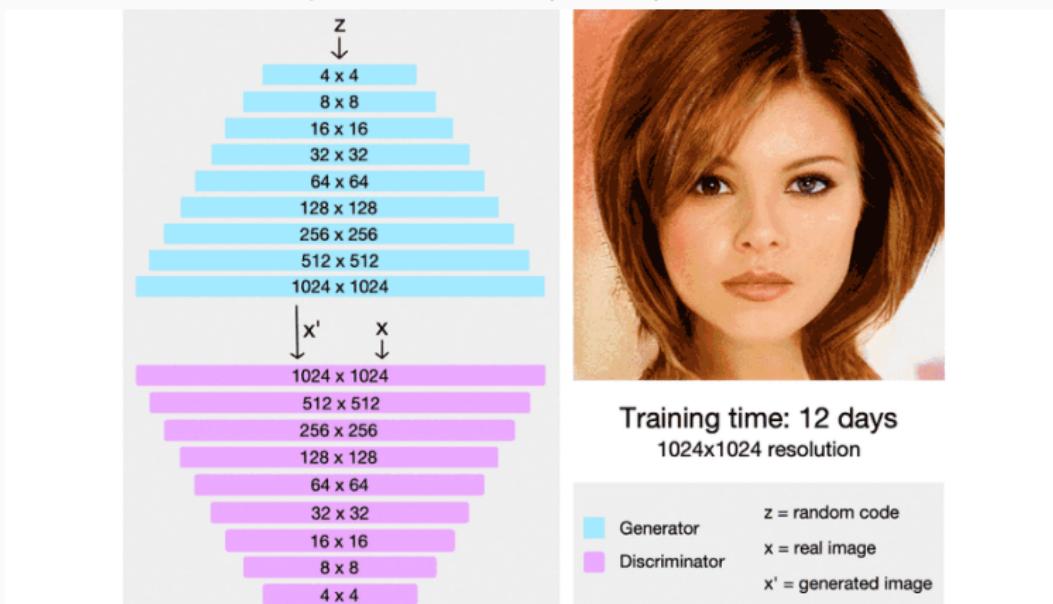
ProGAN

- Важный прорыв пришёл из NVIDIA (Karras et al., 2017)
- Progressive growing (ProGAN): на каждом этапе обучаем GAN создавать картинки вчетверо больше, начиная от 4×4
- И так постепенно увеличивают размерность до 1024×1024



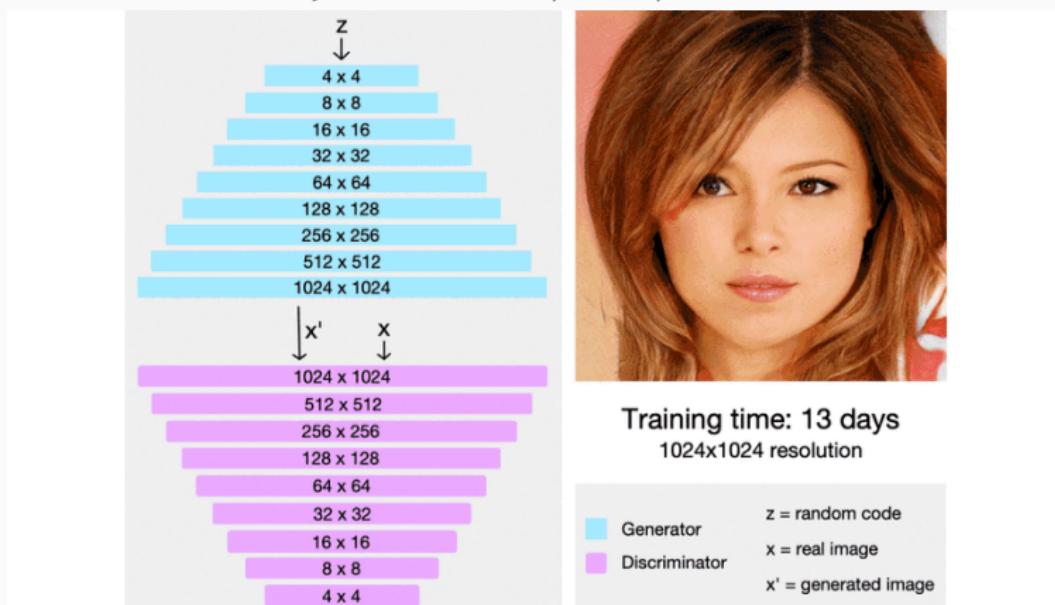
ProGAN

- Важный прорыв пришёл из NVIDIA (Karras et al., 2017)
- Progressive growing (ProGAN): на каждом этапе обучаем GAN создавать картинки вчетверо больше, начиная от 4×4
- И так постепенно увеличивают размерность до 1024×1024



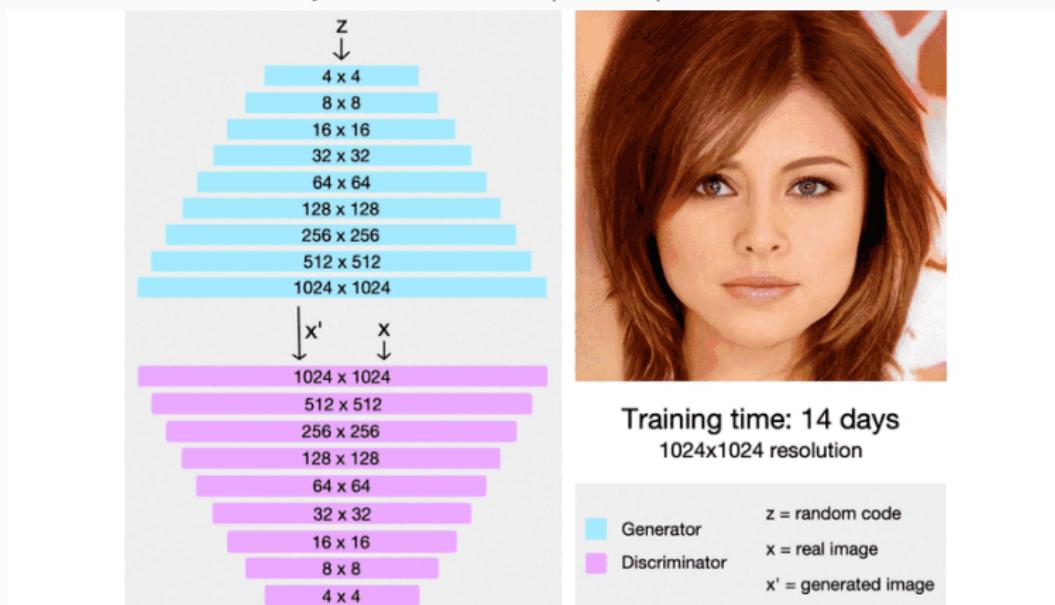
ProGAN

- Важный прорыв пришёл из NVIDIA (Karras et al., 2017)
- Progressive growing (ProGAN): на каждом этапе обучаем GAN создавать картинки вчетверо больше, начиная от 4×4
- И так постепенно увеличивают размерность до 1024×1024

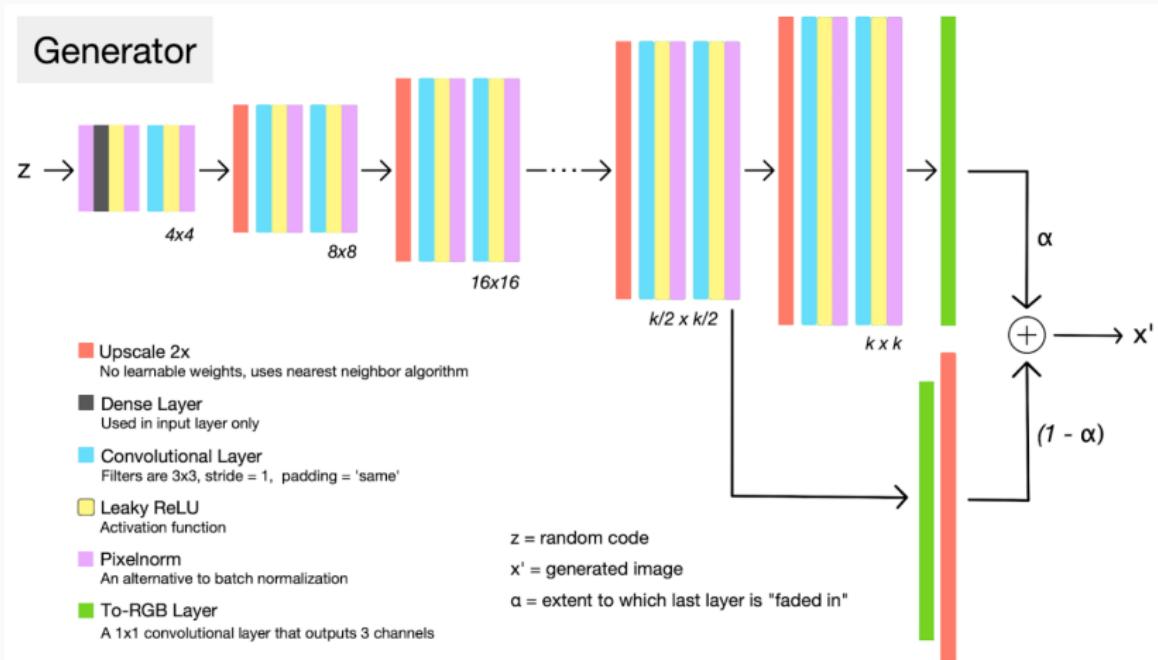


ProGAN

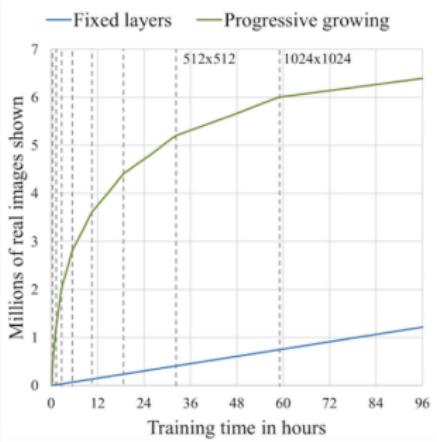
- Важный прорыв пришёл из NVIDIA (Karras et al., 2017)
- Progressive growing (ProGAN): на каждом этапе обучаем GAN создавать картинки вчетверо больше, начиная от 4×4
- И так постепенно увеличивают размерность до 1024×1024



- Именно добавляем новые слои каждый раз; дискриминатор примерно симметричен



- Это помогает экономить время обучения, показывать больше данных за то же время



- Давайте посмотрим:
 - <https://www.youtube.com/watch?v=G06dEcZ-QTg>
 - <https://www.youtube.com/watch?v=36lE9tV9vm0>
- На других категориях до 1024×1024 не доводили, но 256×256 выглядит неплохо

- На других категориях до 1024×1024 не доводили, но 256×256 выглядит неплохо



- И всё это обучается довольно стандартным способом: авторы сравнивают функции ошибки от least squares GAN и от Wasserstein GAN...
- ...wait, what??? Давайте разбираться...

- (Chen et al., 2016): InfoGAN: Interpretable Representation Learning by Information Maximizing Generative Adversarial Nets
- Важное дополнение: было бы круто добавить disentanglement, чтобы разные признаки имели смысл
- В обычных GAN'ах используют просто вектор шума z . В InfoGAN мы его разбиваем на части:
 - z – это действительно несжимаемый шум, источник энтропии;
 - $c = c_1c_2 \dots c_L$ – это латентный код.
- Можно в обычный GAN попробовать это добавить, чтобы генератор стал $G(z, c)$, но надо что-то добавить, чтобы c было важно и G не мог бы просто забыть на него.

- InfoGAN: будем требовать, чтобы была большая взаимная информация (mutual information) $I(c; G(z, c))$, т.е. в распределении $G(z, c)$ должно оставаться много от c .
- Формально – вариационная оценка:

$$\begin{aligned} I(c; G(z, c)) &= H(c) - H(c|G(z, c)) \\ &= \mathbb{E}_{x \sim G(z, c)} [\mathbb{E}_{c' \sim P(c|x)} [\log P(c'|x)]] + H(c) \\ &= \mathbb{E}_{x \sim G(z, c)} [\underbrace{D_{\text{KL}}(P(\cdot|x) \parallel Q(\cdot|x))}_{\geq 0} + \mathbb{E}_{c' \sim P(c|x)} [\log Q(c'|x)]] + H(c) \\ &\geq \mathbb{E}_{x \sim G(z, c)} [\mathbb{E}_{c' \sim P(c|x)} [\log Q(c'|x)]] + H(c) \end{aligned}$$

- И эту нижнюю оценку мы через reparametrization trick параметризуем нейросетью Q ; она обычно почти целиком совпадает с D .

InfoGAN

- Пример на MNIST с $c = c_1c_2c_3$, где c_1 – дискретная метка с 10 категориями (без supervision! с равномерным априорным распределением), и $c_2, c_3 \sim U[-1, 1]$:

| | |
|--|--|
| | |
| | |

(a) Varying c_1 on InfoGAN (Digit type)

(b) Varying c_1 on regular GAN (No clear meaning)

| | |
|--|--|
| | |
| | |

(c) Varying c_2 from -2 to 2 on InfoGAN (Rotation)

(d) Varying c_3 from -2 to 2 on InfoGAN (Width)

- На самом деле по коду c_1 классификатор даёт ошибку 5% на MNIST без всякого supervision.

- 3D-лица:



(a) Azimuth (pose)

(b) Elevation



(c) Lighting

(d) Wide or Narrow

- 3D-стулья:



Wassershtein GAN

- Wassershtein GAN (Arjovsky et al., 2017):
 - что такое обучить распределение вероятностей?
 - это значит минимизировать $KL(p_{\text{data}} \parallel p_{\text{model}})$;
 - но для этого нужно, чтобы p_{model} существовала, а это неверно, если распределение сосредоточено на подмногообразиях малой размерности; вряд ли многообразие p_{model} будет существенно пересекаться с многообразием p_{data} , и KL будет не определено (бесконечно);
 - обычно мы добавляем шум (гауссовский, например), все модели в ML с шумом;
 - но для порождающих моделей шум мешает, делает порождённые примеры размытыми;
 - поэтому обычно шум используют для подсчёта ML, но убирают во время порождения, т.е. шум – это неправильно, но надо для ML.

Wassershtein GAN

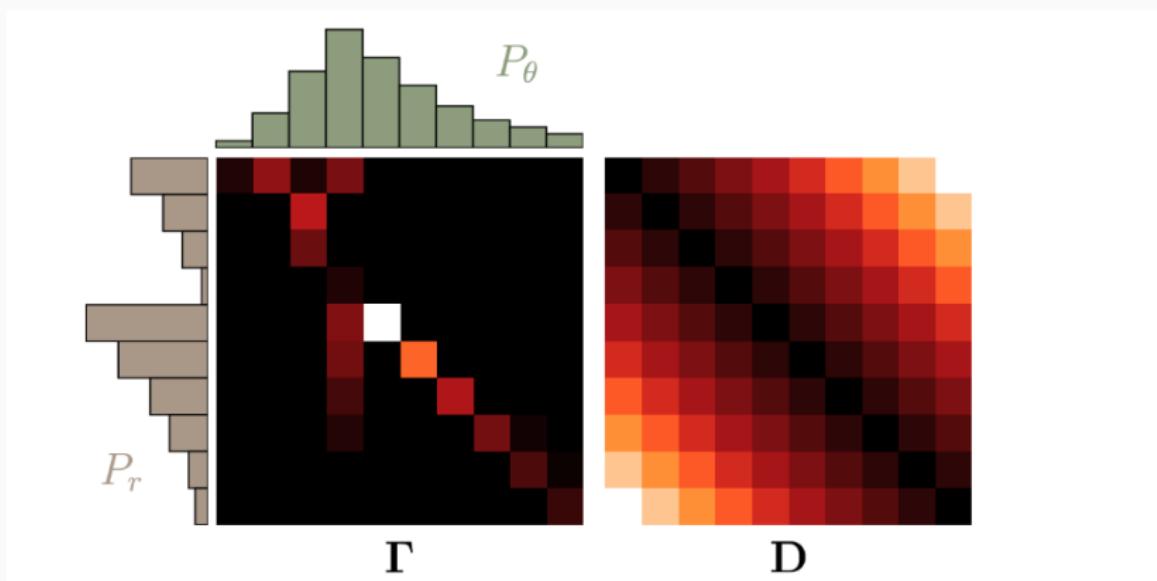
- Wassershtein GAN (Arjovsky et al., 2017): давайте посмотрим на другие метрики близости между p_{data} и p_{model} .
- Earth Mover distance, или Wassershtein-1:

$$W(p_{\text{data}}, p_{\text{model}}) = \inf_{\gamma \in \Pi(p_{\text{data}}, p_{\text{model}})} \mathbb{E}_{(x,y) \sim \gamma} [\|x - y\|],$$

где $\Pi(p_{\text{data}}, p_{\text{model}})$ – множество совместных распределений $\gamma(x, y)$, маргиналы которых – p_{data} и p_{model} .

Wassershtein GAN

- Т.е. $\gamma(x, y)$ показывает, сколько надо «массы» перераспределить от x к y , чтобы превратить p_{data} в p_{model} .



Wassershtein GAN

- Пример: рассмотрим $Z \sim U[0, 1]$, \mathbb{P}_0 – распределение $(0, Z)$ на \mathbb{R}^2 , и $g_\theta(z) = (\theta, z)$, где θ – параметр. Тогда

- $W(\mathbb{P}_0, \mathbb{P}_\theta) = |\theta|,$

- $JS(\mathbb{P}_0, \mathbb{P}_\theta) = \begin{cases} \log 2 & \text{if } \theta \neq 0, \\ 0 & \text{if } \theta = 0, \end{cases}$

- $KL(\mathbb{P}_\theta \| \mathbb{P}_0) = KL(\mathbb{P}_0 \| \mathbb{P}_\theta) = \begin{cases} +\infty & \text{if } \theta \neq 0, \\ 0 & \text{if } \theta = 0, \end{cases}$

- and $\delta(\mathbb{P}_0, \mathbb{P}_\theta) = \begin{cases} 1 & \text{if } \theta \neq 0, \\ 0 & \text{if } \theta = 0. \end{cases}$

- Т.е. только EM-расстояние действительно куда-то сходится при $\theta \rightarrow 0$, а это ведь очень похоже на обучение распределения, сосредоточенного на подмногообразии.

Wassershtein GAN

- Можно доказать, что $W(p_{\text{data}}, p_{\text{model}})$ – непрерывная функция от параметров θ распределения p_{model} при достаточно слабых условиях.
- А двойственность Монжа-Канторовича (Kantorovich-Rubinstein duality) говорит, что инфимум

$$W(p_{\text{data}}, p_{\text{model}}) = \inf_{\gamma \in \Pi(p_{\text{data}}, p_{\text{model}})} \mathbb{E}_{(x,y) \sim \gamma} [\|x - y\|]$$

эквивалентен

$$W(p_{\text{data}}, p_{\text{model}}) = \sup_{\|f\|_L \leq 1} (\mathbb{E}_{x \sim p_{\text{data}}} [f(x)] - \mathbb{E}_{x \sim p_{\text{model}}} [f(x)]),$$

где супремум берётся по всем функциям с липшицевой константой ≤ 1 .

- А мы хотим обучить порождающую модель $p_{\text{model}} = g_{\theta}(z)$.
- Давайте всё параметризуем нейросетями.

Wassershtein GAN

- Сеть f_w для функции f и сеть для g_θ . Тогда:
 - для данного g_θ обучим веса f_w , максимизируя

$$\mathbb{E}_{x \sim p_{\text{data}}} [f(x)] - \mathbb{E}_{x \sim p_{\text{model}}} [f(x)];$$

- для данного f_w подсчитаем

$$\begin{aligned}\nabla_\theta W(p_{\text{data}}, p_{\text{model}}) &= \nabla_\theta (\mathbb{E}_{x \sim p_{\text{data}}} [f(x)] - \mathbb{E}_{x \sim p_{\text{model}}} [f(x)]) = \\ &= -\mathbb{E}_{z \sim z} [\nabla_\theta f_w(g_\theta(z))].\end{aligned}$$

- А чтобы f_w оставалось липшицевым, можно просто weight clipping сделать для градиентов.

Wassershtein GAN

- Итого алгоритм обучения:

Algorithm 1 WGAN, our proposed algorithm. All experiments in the paper used the default values $\alpha = 0.00005$, $c = 0.01$, $m = 64$, $n_{\text{critic}} = 5$.

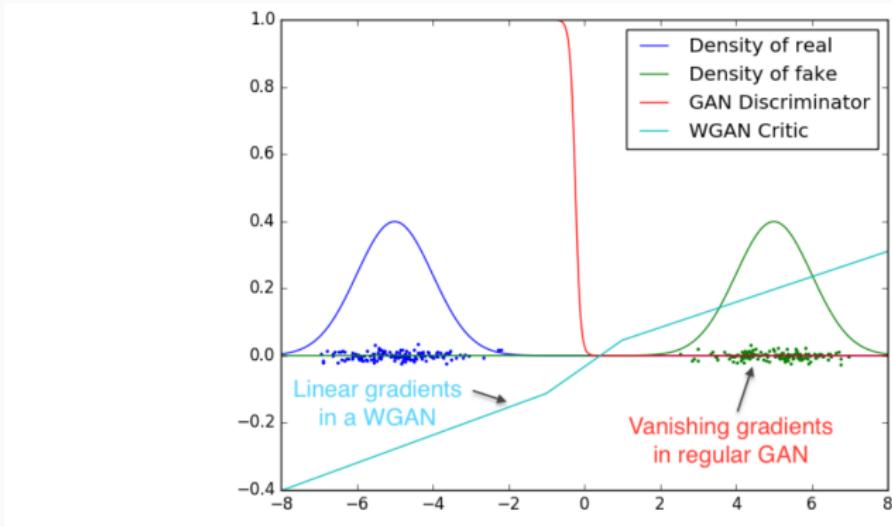
Require: : α , the learning rate. c , the clipping parameter. m , the batch size. n_{critic} , the number of iterations of the critic per generator iteration.

Require: : w_0 , initial critic parameters. θ_0 , initial generator's parameters.

```
1: while  $\theta$  has not converged do
2:   for  $t = 0, \dots, n_{\text{critic}}$  do
3:     Sample  $\{x^{(i)}\}_{i=1}^m \sim \mathbb{P}_r$  a batch from the real data.
4:     Sample  $\{z^{(i)}\}_{i=1}^m \sim p(z)$  a batch of prior samples.
5:      $g_w \leftarrow \nabla_w \left[ \frac{1}{m} \sum_{i=1}^m f_w(x^{(i)}) - \frac{1}{m} \sum_{i=1}^m f_w(g_\theta(z^{(i)})) \right]$ 
6:      $w \leftarrow w + \alpha \cdot \text{RMSProp}(w, g_w)$ 
7:      $w \leftarrow \text{clip}(w, -c, c)$ 
8:   end for
9:   Sample  $\{z^{(i)}\}_{i=1}^m \sim p(z)$  a batch of prior samples.
10:   $g_\theta \leftarrow -\nabla_\theta \frac{1}{m} \sum_{i=1}^m f_w(g_\theta(z^{(i)}))$ 
11:   $\theta \leftarrow \theta - \alpha \cdot \text{RMSProp}(\theta, g_\theta)$ 
12: end while
```

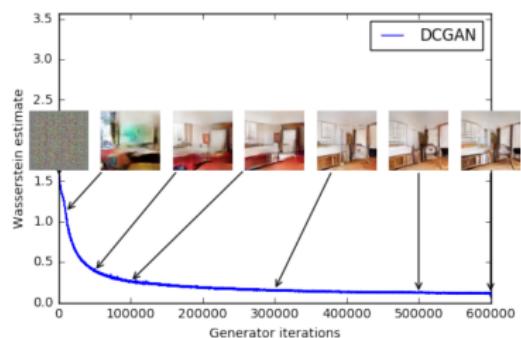
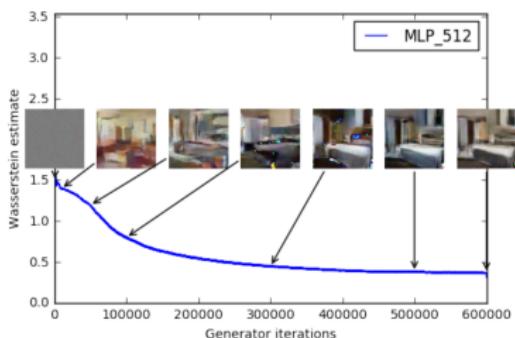
Wassershtein GAN

- Пример, на котором видно, что в WGAN можно спокойно обучать f_w до сходимости, а в обычном GAN дискриминатор, может, и не стоит так обучать:



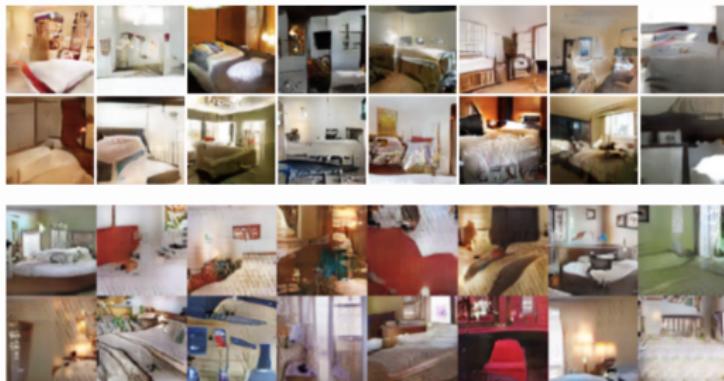
Wassershtein GAN

- Качество тесно коррелирует с функцией ошибки; слева тут просто полносвязная сеть в качестве генератора, справа – DCGAN:



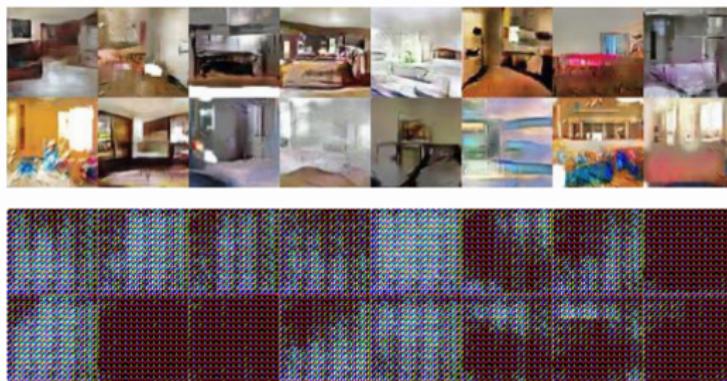
Wassershtein GAN

- WGAN устойчивее к изменению архитектуры; вот обычные WGAN и DCGAN (снизу):



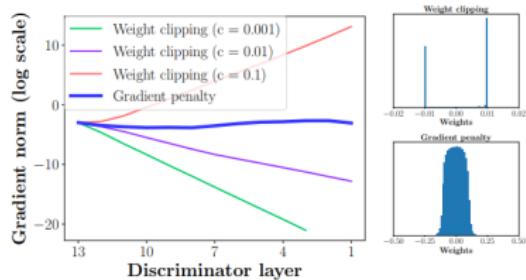
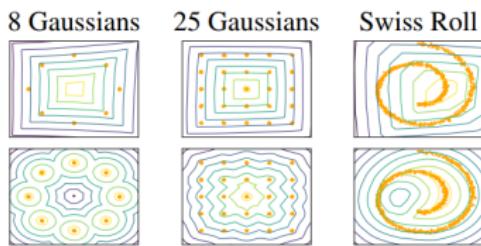
Wassershtein GAN

- А вот что будет, если убрать из генератора batchnorm и сделать фильтров поменьше (одинаковое число на каждом уровне):



Wassershtein GAN

- (Gulrajani et al., 2017): Improved Training of Wasserstein GANs
- Weight clipping в критике на самом деле ведёт к проблемам, не обучаются более высокие моменты распределений и градиенты взрываются/затухают
- Лучше делать мягкий регуляризатор на градиент, типа
$$\lambda \mathbb{E}_{\hat{x} \sim P_{\hat{x}}} \left[(\|\nabla_{\hat{x}} D(\hat{x})\|_2 - 1)^2 \right]$$



Спасибо!

Спасибо за внимание!

