

Случай двух классов!

confusion matrix (матрица ошибок).

	y=1	y=0
$\hat{y}=1$	True Positive (TP)	False Positive (FP)
$\hat{y}=0$	False Negative (FN)	True Negative (TN)

accuracy — доля правильных ответов

$$accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

Достоинство: интерпретируема.

Недостаток: обманывает, если выборки несбалансированы

precision (точность) и recall (полнота).

$$precision = \frac{TP}{TP + FP}$$

Precision == доля правильно распознанных "1" из всех распознанных как "1".

Судебная система — мало

$$recall = \frac{TP}{TP + FN}$$

recall == доля правильно распознанных "1" из всех "1".

Пример: если составляется список рассылки, надо не пропустить потенциального покупателя.

Precision и recall не зависят, в отличие от accuracy, от соотношения классов и потому применимы в условиях несбалансированных выборок.

Если повысить Recall, делая классификатор более «оптимистичным», то уменьшится Precision из-за увеличения числа ложно-положительных ответов.

Если же вы делаете классификатор более «пессимистичным», то вырастет Precision, но уменьшится Recall.

Удобно для характеристики классификатора использовать одну величину F_1 : среднее гармоническое величин precision и recall

$$F_1 = 2 \cdot \frac{precision \cdot recall}{precision + recall}$$

Придаем одинаковый вес точности и полноте, поэтому F-мера будет падать одинаково при уменьшении и точности и полноты.

$$F_\beta = (1 + \beta^2) \cdot \frac{precision \cdot recall}{\beta^2 \cdot precision + recall}$$

$0 < \beta < 1$ если важнее точность,
 $\beta > 1$ приоритет отдается полноте.

Кривая ошибок или ROC-кривая

Каждая точка на графике соответствует выбору некоторого порога.

False Positive Rate (FPR) (по горизонтальной оси):

$$FPR = \frac{FP}{FP + TN}$$

True Positive Rate (TPR) (по вертикальной оси):

$$TPR = recall = \frac{TP}{TP + FN}$$

Каждая точка на графике соответствует выбору некоторого порога.

AUC

http://mlwiki.org/index.php/ROC_Analysis

AUC считается по всем возможным пороговым значениям...

Если классов больше 2?